Parallellprogrammering och multithreading i Python

En process inom programmering är ett program som körs. Datan som processen använder laddas in i datorns internminne, och programmet exekveras av datorns processor. Den utför alla beräkningar och lagrar och läser data i datorns internminne och hårddisk. Varje process har sitt eget allokerade minne.

En tråd (eng. thread) är en beräkningsenhet i en given process, och en process kan även köras på flera trådar samtidigt. Trådarna har då en del av processens minne, och delar det med dess andra trådar. Så kallad multithreading ämnar att öka effektiviteten av användningen av processorns kärnor genom att låta flera trådar skapas av en process och tilldelas olika uppgifter.

Multithreading är mindre användbart när större beräkningar ska utföras, och brukar istället användas mer för processer som involverar operativsystemet. Det handlar oftast om processer som läser från eller skriver till datorns hårddisk, eller som skickar eller tar emot data via datorns nätverk. Det är då vanligt att program sitter väntandes på nästa instruktion utan att göra något under tiden. Då går det att skynda på arbetet genom att låta ett program utföra andra uppgifter i väntan på något. Exempelvis som att utföra en beräkning i väntan på att en nedladdning ska bli klar, istället för att vänta med beräkningen tills efter att nedladdningen är klar.

Parallellprogrammering är bättre för program som enbart förlitar på processorn istället. Det rör sig oftast om program som utför stora beräkningar. Sådana program fördelas mellan processorns kärnor så att den kan utföra fler beräkningar samtidigt.

Parallellprogrammering

Vi kommer att implementera en enkel metod som härmar en beräkningsintensiv funktion. Vi kommer att köra programmet flera gånger och mäta exekveringstiden för programmet. Börja med att importera följande metoder i ett tomt Python-script example.py,

```
from time import perf_counter as pc
from time import sleep as pause
```

Vår metod kommer att använda time-modulens sleep()-method för att likna en process som tar en viss tid att slutföra.

```
def runner():
    print("Performing a costly function")
    pause(1)
    print("Function complete")
```

Vi kör metoden och tar tid före och efter processen har körts. Vi skriver sedan ut hur lång tid körningen tog som en så kallad f-sträng, som helt enkelt är en enklare version av "".format() där vi kan sätta in variablerna direkt in i strängen.

```
if __name__ == "__main__":
    start = pc()
    runner()
    end = pc()
    print(f"Process took {round(end-start, 2)} seconds")
```

```
$ python3 example.py
Performing a costly function
Function complete
Process took 1.0 seconds
```

Vi kör nu metoden tio gånger för att se om det tar ungefär tio sekunder att köra den som förväntat.

```
if __name__ == "__main__":
    start = pc()
    for _ in range(10):
        runner()
    end = pc()
    print(f"Process took {round(end-start, 2)} seconds")
```

```
$ python3 example.py
Performing a costly function
Function complete
Process took 10.02 seconds
```

Då metoden anropades och exekverades tio gånger sekventiellt tog det ungefär 10.02 sekunder att slutföra programmet, vilket verkar stämma väl överens med våra förväntningar.

Genom att använda Pythons multiprocessing-modul kan vi köra metoden flera gånger parallellt. Dagens datorer är oftast flerkärniga, och kan därför köra flera program samtidigt. Den här modulen kommer att hjälpa oss med att skicka arbetsuppgifter till de olika kärnorna för att köra delar av programmet parallellt. Importera modulen längst upp i din kod.

```
import multiprocessing as mp
```

För att skapa en process måste vi skapa ett processobjekt med metoden som vi vill köra som parametern target. (Det finns även en parameter vid namn args som kan användas för att skicka in en lista till metoden.) Vi skapar nu flera processobjekt genom att skriva följande kod.

```
p1 = mp.Process(target=runner)
p2 = mp.Process(target=runner)
```

För att starta processerna behöver vi anropa metoden start som är associerad med processens objekt.

```
p1.start()
p2.start()
```

Låt oss nu beräkna hur länge programmet kommer att köras.

```
if __name__ == "__main__":
    start = pc()
    p1 = mp.Process(target=runner)
    p2 = mp.Process(target=runner)
    p1.start()
    p2.start()
    end = pc()
    print(f"Process took {round(end-start, 2)} seconds")
```

```
$ python3 example.py
Process took 0.02 seconds
Performing a costly function
Performing a costly function
Function complete
Function complete
```

Det som vi ser nu är att processerna verkar ha tagit 0.02 sekunder. Det är så klart fel då att vi kan se att det finns kvar utskrifter efter den sista utskriften i vår metod. Det som hände här var att processerna startade samtidigt, men att programmet fortsatte att köras trots att processerna inte var klara än. Problemet här är att vi inte vet exakt hur lång tid programmet tog att utföra processerna eftersom att metoderna inte längre körs sekventiellt.

Vi löser det här problemet genom att använda metoden join för att vänta in processerna tills dess att alla är klara.

```
p1.join()
p2.join()
```

Vi mäter nu hur lång tid programmet egentligen tog att köra.

```
if __name__ == "__main__":
1
            start = pc()
2
3
            p1 = mp.Process(target=runner)
            p2 = mp.Process(target=runner)
4
5
            p1.start()
6
            p2.start()
            p1.join()
7
            p2.join()
8
            end = pc()
9
10
            print(f"Process took {round(end-start, 2)} seconds")
```

```
$ python3 example.py
Performing a costly function
Performing a costly function
Function complete
Function complete
Process took 1.1 seconds
```

Nu ser vi hur programmet enbart tog ungefär en sekund att köra, trots att metoden kördes två gånger och stannades en sekund varje gång. Vi halverade alltså exekveringstiden av programmet.

Om vi vill köra många processer samtidigt så kan vi starta och köra dem i en loop. Om vi vill samla in dem så måste vi däremot göra det utanför loopen. Då måste vi lagra våra processer i en lista så att vi kan iterera över listan av processer och samla in dem då de är klara. Om vi samlar in dem direkt i loopen så kommer de att köras sekventiellt igen.

Här är generisk kod för att köra 10 parallella körningar some_method med argument some_var.

Futures

Om vi även vill få tillbaka resultaten av våra metoder så måste vi använda klassen Manager för att använda oss av några arbetsmetoder som lagrar värden åt oss. Den här klassen kan vara lite svårhanterlig, så vi kommer istället att betrakta en annan Python-modul som kan köra parallellprogram och hantera insamlingen och returerna åt oss, som på så sätt är mer lätthanterlig. Den här modulen är bara en av många sätt att visa hur de här processerna fungerar innan vi använder den mer användarvänliga modulen concurrent.futures.

Ta bort importen av multiprocessing, och importera istället concurrent.futures.

```
import concurrent.futures as future
```

Modulen Futures har en gruppexekverare som är lättast att köra i en så kallad context manager (ett with-statement i Python). Vi kallar då på metoden submit genom att skicka in metoden som vi vill köra tillsammans med eventuella inparametrar som vi vill ska följa med vår metod då den körs. För att sedan komma åt våra returvärden kallar vi på metoden result för att komma åt processobjekten. Den här modulen låter oss samla processerna genom att automatiskt vänta på processer tills dess att de är klara innan vi lämnar withdelen av koden.

Vi börjar med att uppdatera vår metod runner genom att ge den en inparameter och en retursträng.

```
def runner(n):
    print(f"Performing costly function {n}")
    pause(n)
    return f"Function {n} has completed"
```

Istället för att köra processerna i en loop kan vi använda exekveringsmetodens metod map. Med exekveringsmetod menar vi den metod som exekverar metoden map. Python har en inbyggd metod map som tar en metod och en lista av variabler som sedan sedan itereras över för att exekvera metoden varje element i listan. Användningen av den inbyggda metoden visas i följande exempel.

```
>>> def sq(x):
    return x**2

>>> for x in map(sq, [2,3,4,5]):
    print(x)

4

9

16
25
```

Låt oss nu deklarera en lista heltal som vi tar som inparameterar till vår metod runner. Vi skapar sedan en variabel vid namn results för att lagra våra returvärden som exekveringsmetodens metod map returnerar. Vi skickar sedan vår metod tillsammans med listan av heltal in i anropet. Slutligen så itererar vi över det returnerade objektet map och skriver ut resultaten som det returnerar.

```
if __name__ == "__main__":
1
            start = pc()
2
3
            with future.ProcessPoolExecutor() as ex:
4
                    p = [5, 4, 3, 2, 1]
5
                    results = ex.map(runner, p)
6
7
                    for r in results:
8
                             print(r)
9
10
11
            end = pc()
12
            print(f"Process took {round(end-start, 2)} seconds")
```

```
$ python3 example.py
Performing costly function 5
Performing costly function 4
Performing costly function 3
Performing costly function 2
Performing costly function 1
Function 3 has completed
Function 2 has completed
Function 1 has completed
Function 5 has completed
Function 4 has completed
Process took 5.21 seconds
```

Som vi ser så exekverades metoderna i en annan ordning än i den som de anropades. Det sker eftersom att det inte finns något sätt att veta hur upptagen en given processorkärna är då programmet skickar uppgiften till den. Så metoderna kommer att startas i olika ordning varje gång du kör programmet. Den process som kör processerna håller däremot koll på deras returvärden och försäkrar oss om att de returneras i den ordning som de exekverades i. Modulen futures har även en metod vid namn as_completed som returnerar resultaten i den ordning som de kom in. (Den kan inte användas tillsammans med map, men det går att använda den tillsammans med metoden submit som tidigare användes i en loop).

Multithreading

Användningen av modulen concurrent.futures genom att köra flera trådar är inte svårare än att ändra ProcessPoolExecutor i en klass till ThreadPoolExecutor. I övrigt är proceduren precis densamma.

```
if __name__ == "__main__":
1
            start = pc()
2
3
            with future. ThreadPoolExecutor() as ex:
4
5
                    p = [5, 4, 3, 2, 1]
                    results = ex.map(runner, p)
6
7
                    for r in results:
8
                             print(r)
9
10
            end = pc()
11
            print(f"Process took {round(end-start, 2)} seconds")
12
```

```
$ python3 example.py
Performing costly function 5
Performing costly function 4
Performing costly function 3
Performing costly function 2
Performing costly function 1
Function 5 has completed
Function 4 has completed
Function 3 has completed
Function 2 has completed
Function 1 has completed
Punction 1 has completed
Process took 5.01 seconds
```

Som ni ser så är utdatan från programmet lite annorlunda. Metoderna exekveras här i den ordning som de anropades. Det beror på att vi inte längre använder flera kärnor för att utföra uppgiften. Syftet med den här koden är så klart bara att illustrera proceduren, men det är inte beräkningsintensivt eller knutet till operativsystemet, så trådproceduren fungerar precis lika bra i det här fallet, och processerna slutfördes återigen efter cirka fem sekunder.

Länkar till den som vill lära sig mer, och se andra exempel:

https://www.machinelearningplus.com/python/parallel-processing-python/

https://www.geeksforgeeks.org/parallel-processing-in-python/